

因子研究框架（开发阶段）任务与人员分配

模块	任务	人员
数据获取	从 API / 数据库拉取原始数据，并原样落盘，保证可追溯	1
数据维护与引擎外清洗	维护表结构（primary key、索引）、表间关联（join）、数据对齐与一致性；对部分数据进行清洗并重新落盘	1
计算引擎开发	实现 DSL → DAG → 执行链路；支持表达式解析与计算流程生成	1-2
执行优化	拆分 DSL 计算步骤并向量化；实现计算顺序优化（如先 sum 再 filter）；避免 apply；实现并发调度（粒度、数量、资源利用）	1-2（可与引擎开发重叠）
数据适配与引擎内清洗	为不同数据类型实现处理函数；在 DSL 执行过程中调用；新数据接入时补充适配逻辑	1
因子计算与落盘	执行计算图生成因子值；存储结果并记录版本与元数据	0.5-1
因子评估	实现截面（IC、分组）与时序评估；输出标准化评估结果	1
因子入库	根据评估筛选因子；标签化与因子库管理	0.5-1
AI 接口开发	实现 prompt → config 的模型调用接口；统一输出格式	1
Prompt 工程	设计通用与分场景 prompt（研报/论文）；约束输出为合法 DSL 配置	1
Config 试运行	编写脚本执行 config；检查是否可解析与运行	0.5-1
Config 质量评估	检查表达式合法性、运行错误、耗时；输出结构化评估结果	1
AI 迭代修正	实现“生成→试运行→评估→反馈→再生成”的闭环，直到 config 达标	1

因子研究框架（开发阶段）流程与任务分配

一、整体流程

原始数据获取并落盘 → 数据维护与引擎外清洗 → 计算引擎开发与执行 → 因子结果落盘 → 因子评估 → 入库

↘

AI 文本解析 → DSL 配置生成 → 试运行 → 质量评估 → 迭代修正

二、主流程拆解与任务分配

1. 原始数据获取并落盘（简单 Python 脚本撰写，API 调用）

流程：

- 从 API 或数据库获取原始数据
- 原样存储到本地或数据库（保证可追溯）

2. 数据维护与引擎外清洗（数据清洗及数据库维护工作）

流程：

- 维护数据表结构（primary key，如 ticker + date）
- 维护表间关系与对齐（join 逻辑）
- 处理数据一致性问题
- 对部分数据进行引擎外清洗并重新落盘

3. 计算引擎开发与执行（表达式计算核心优化，pandas 运算深度优化）

流程：

- DSL → 解析为计算图（DAG） → 执行 → 结果落盘

执行优化任务（必须实现）：

- 对表达式：
- `filter(sum(quote_qty) > 100)`
- 要求按如下方式实现执行逻辑：
 - 先计算 `sum(quote_qty)` 并生成中间列
 - 基于该中间列生成布尔条件
 - 再执行 `filter` 操作
- 禁止通过单次 `apply` 完成全部计算
- 所有 DSL 表达式必须拆分为可向量化执行的步骤

- 禁止使用无法优化的黑盒计算方式
- 并发执行需完成以下工作：
 - 明确并发粒度（按股票 / 时间 / 因子）
 - 控制并发数量
 - 实现任务调度，最大化利用计算资源
- 针对 DSL 适配不同数据：
 - 同一 DSL 表达式在不同数据类型下需调用不同执行函数
 - 新数据接入时，需要补充对应的执行实现
 - 不允许修改 DSL 表达式本身来适配数据

4. 引擎内清洗与数据适配（深度理解数据，整理转化数据格式）

流程：

- 在 DSL 执行过程中调用对应的数据处理函数
- 为不同数据类型维护独立处理逻辑
- 新数据接入时补充处理规则

说明：

- 属于数据维护的一部分，但在计算阶段执行

5. 因子结果落盘（因子信息汇总，因子版本管理）

流程：

- 存储因子值
- 记录版本信息和元数据

6. 因子评估（因子有效性分析）

流程：

- 截面因子：IC / Rank IC / 分组收益
- 时序因子：预测能力 / 策略收益
- 预留扩展：事件驱动 / 高频

7. 入库（因子库结构设计）

流程：

- 根据评估结果筛选因子
- 标签化（风格 / 类型）

- 管理因子库

三、AI 模块流程与任务分配

1. AI 整体流程

prompt + 研报/论文

- AI 生成第一版 config
- 试运行 (python 脚本)
- 质量评估 (表达式/性能)
- 不合格返回 AI
- 生成第二版 config
- 再试运行
- ...循环
- 输出最终 config

2. AI 模块拆解

2.1 AI 接口 (prompt → config)

流程:

- 实现模型调用接口
- 打通 prompt → config 输出
- 统一 config 格式

2.2 Prompt 工程

流程:

- 设计通用 prompt 模板
- 针对不同文本设计模板 (研报 / 论文)
- 约束输出为合法 DSL 配置

2.3 试运行模块 (python 接口脚本)

流程:

- 使用 python 脚本执行 config
- 检查:
 - 是否能被解析
 - 是否能正常运行

2.4 Config 质量评估

必须实现以下检查：

- 检查是否存在无法解析或无法运行的表达式
- 检查执行过程中是否报错
- 检查执行时间是否超过预设阈值
- 输出结构化评估结果（供 AI 下一轮使用）

2.5 AI 迭代修正流程（核心任务）

要求实现如下闭环：

1. 将评估结果作为输入反馈给 AI
2. 要求 AI 基于错误信息修正 config
3. 生成第二版 config
4. 重复“生成 → 试运行 → 评估”流程
5. 直到 config 满足所有运行和性能要求